《泰坦尼克号-从灾难中学习机器学习》

期末课程设计报告

—

课设勿盗

摘要：

Kaggle 平台的“泰坦尼克号-从灾难中学习机器学习”是经典的入门级数据科学竞赛，旨在通过分析乘客的年龄、性别、船舱等级等信息，预测乘客在泰坦尼克号沉船事故中的生存状况，帮助掌握数据处理、模型构建与评估等机器学习基础技能。主要工作：（1）、首先，对原始数据集进行**清洗**，**处理缺失值和异常值**，并通过**特征工程**提取有价值的信息；（2）、接着，分别运用**逻辑回归、随机森林、XGBoost 和 SVM 模型**进行训练；为准确评估模型性能，使用**交叉验证**划分数据集；通过网格搜索等方法对模型**超参数调优**；（3）、最后，采用**模型集成**策略融合多个模型的预测结果。创新点在于系统性对比多种模型表现，结合交叉验证、超参数调优与模型集成形成完整优化流程，针对数据集特点调整模型，避免盲目搜索参数。

关键词：Kaggle 泰坦尼克号；逻辑回归；随机森林；XGBoost；SVM；交叉验证；超参数调优；模型集成

课设勿盗

目录

一、引言 1

1.1 研究背景 1

1.1.1 泰坦尼克号事件的历史意义 1

1.1.2 机器学习在社会科学中的应用价值 1

1.2 问题描述 1

1.2.1 Kaggle 比赛任务说明 1

1.2.2 二分类问题的技术挑战 1

1.3 研究目标 2

1.3.1 预测精度提升 2

1.3.2 特征工程方法论实践 2

二、数据处理 2

2.1 数据导入与初步观察 2

2.2 缺失值处理 3

2.3 异常值处理 3

2.4 数据类型转换 3

2.5 特征工程 3

三、模型构建与优化 3

3.1 逻辑回归模型 3

3.1.1 模型介绍 3

3.1.2 模型构建与训练 4

3.1.3 模型优化 5

3.2 随机森林算法模型 5

3.2.1 模型介绍 5

3.2.2 模型构建与训练 6

3.2.3 模型优化 7

3.3 XGBoost 梯度提升树模型 8

3.3.1 模型介绍 8

3.3.2 模型构建与训练 8

3.3.3 模型优化 9

3.4 SVM 模型 10

3.4.1 模型介绍 10

3.4.2 模型构建与训练 11

3.4.3 模型优化 12

3.5 模型集成 13

四、总结 13

附录： ..... 错误!未定义书签。

课设勿盗

一、引言

1.1 研究背景

1.1.1 泰坦尼克号事件的历史意义

泰坦尼克号的沉没是历史上最为人熟知的海难事件之一。1912 年 4 月 15 日，这艘被视作“永不沉没”的 RMS 泰坦尼克号，在其处女航途中，不幸与冰山相撞后沉入海底。由于船上救生艇数量严重不足，未能满足全员需求，致使船上 2224 名乘客与船员中，多达 1502 人丧生，酿成了一场惨痛的悲剧。尽管在这场灾难中，生存与否在一定程度上存在运气成分，但研究发现，某些群体的生还概率明显高于其他群体。

1.1.2 机器学习在社会科学中的应用价值

在社会科学领域，机器学习凭借强大的数据处理与模式识别能力，为研究带来了全新视角和方法。通过对海量社会调查数据、历史档案、网络行为数据的分析，机器学习能够挖掘出传统研究方法难以发现的隐藏规律。例如，在研究社会分层与流动时，可基于个人教育、职业、收入等多维度数据，构建预测模型分析阶层跃迁的影响因素；在公共政策评估中，利用历史政策实施数据和社会反馈，预测不同政策方案的实施效果，为政策优化提供量化依据。此外，机器学习还能应用于舆情分析，实时捕捉社会舆论动态，助力理解公众情绪和社会心态的演变，从而为社会科学研究和公共管理决策提供更科学、精准的支持。

1.2 问题描述

1.2.1 Kaggle 比赛任务说明

在本次 Kaggle 挑战赛中，要求构建一个预测模型，通过分析乘客的姓名、年龄、性别、社会经济阶层等数据，探寻“哪些特征的人更有可能在这场灾难中幸存”这一关键问题的答案。要用主办方给了泰坦尼克号乘客的姓名、年龄、性别、船舱等级这些信息的原始数据训练模型，找出影响乘客能否存活的关键因素，比如是不是女性、年龄大小、船舱等级高低等等。最后用训练好的模型，对另一份只有乘客信息但没有生存结果的数据，预测他们能不能在沉船事故中活下来，这能帮我更好地理解当时哪些人更容易幸存。

1.2.2 二分类问题的技术挑战

首先是数据质量问题，原始数据里有很多缺失值，比如乘客年龄、船舱号等信息不全，**直接删除或简单填补数据**，可能会让模型出错。其次，特征复杂难处理，像乘客姓名、船舱编号这类数据，不能直接放进模型，得进行**数据预处理**，而且还得判断哪些特征对生存预测真正有用。再者，模型容易陷入**过拟合或欠拟合**，比如逻辑回归模型可能太简单，遗漏关键信息，而随机森林等复杂模型又可能把数据里的噪声当成规律，在新数据上表现很差。最后，调优和集成模型也不容易，**超参数设置**没有固定

套路，得反复尝试；把多个模型结果融合时，怎么给不同模型**合理分配权重**，才能让预测最准，这些都需要不断摸索和验证。

1.3 研究目标

1.3.1 预测精度提升

提升预测精度主要从三方面入手：

1.**优化数据处理**，比如用**统计方法（均值、中位数）**填补年龄等缺失值，将姓名、船舱号等信息转化为计算机能理解的数字特征，通过数据清洗与特征工程，提升数据质量，**消除数据噪声与冗余**，增强数据的完整性与规范性 ，为后续模型训练奠定坚实基础。

2.**调整模型参数**，用网格搜索、随机搜索等方法，尝试不同的**超参数组合**，找到逻辑回归、随机森林等模型的最佳“设置”；

3.**融合多个模型**，将逻辑回归、XGBoost 等不同模型的预测结果综合起来，发挥各自优势，避免单一模型的局限性，最终提高预测的准确性。

1.3.2 特征工程方法论实践

使如下几种实用的方法做特征工程：

1.处理缺失值。比如“年龄”这一列有不少空白数据，用**平均值或者中位数填补空值**；“船舱号”很多缺失，直接标记成“未知”。这样能保证数据完整，确保模型能够稳定运行并有效学习数据特征 。

2.把非数字数据变成数字。像“性别”这一列，把“男”写成 0，“女”写成 1；“登船港口”有三个不同的港口，分别用 0、1、2 表示。这样模型就能理解这些信息了。

3.创建新特征。例如“船舱等级”和“票价”有关系，就把它们**组合成一个新特征**；还根据“年龄”和“是否儿童”的关系，加了个“儿童”标签。这些新特征能让模型发现更多隐藏规律。

4.简化数据。有些特征太复杂，比如“姓名”对预测生存没太大用，就**直接删掉**；“船舱号”只保留首字母，减少信息冗余。通过这些操作，让数据更有用，帮模型做出更准确的预测 。

二、数据处理

2.1 数据导入与初步观察

1. 导入数据：使用 Python 的 Pandas 库读取训练集与测试集数据。

2. 数据概览：通过 info() 和 describe() 函数查看数据结构、数据类型、缺失值情况及数值型变量的统计特征。

课设勿盗

2.2 缺失值处理

1. **数值型变量**：对“年龄”等数值型变量，采用**均值或中位数填充缺失值**。
2. **分类型变量**：如“船舱号”“登船港口”，使用**众数填充或标记为特定缺失类别**。

2.3 异常值处理

1. **识别异常值**：利用箱线图、统计分析等方法识别数值型变量中的异常值。
2. **处理异常值**：对极端异常值采用**直接舍去**，或替**换为合理边界值**。

2.4 数据类型转换

1. **分类型变量编码**：对“性别”“登船港口”等分类型变量，使用**独热编码**转换为数值型。
2. **日期时间等特殊类型处理**：（若存在）将日期时间格式转换为模型可处理的数值形式。

2.5 特征工程

1. **特征提取**：从“姓名”“船舱号”等复杂特征中提取有价值信息，如从姓名中提取头衔，从船舱号提取甲板信息。
2. **特征衍生**：根据现有特征组合创建新特征，如结合“年龄”和“性别”生成新的分类特征，或根据“船舱等级”与“票价”的关系构建新的比例特征。
3. **特征选择**：使用相关性分析、方差阈值等方法筛选关键特征，去除冗余或无关特征 。

三、模型构建与优化

3.1 逻辑回归模型

3.1.1 模型介绍

逻辑回归（Logistic Regression）是一种经典的**有监督机器学习算法**，它主要用于**解决分类问题**。它的核心原理是通过构建**线性回归方程**，将输入特征加权求和，再利用逻辑函数（Sigmoid 函数）将结果压缩到 0 到 1 之间，这个数值可以理解为样本属于某一类别的概率。例如在泰坦尼克号生存预测中，输出值越接近 1，表示乘客生存的概率越高；越接近 0，则表示生存概率越低。当概率超过设定的阈值（通常为 0.5）时，就判定为正类（生存），否则为负类（未生存）。逻辑回归模型**简单易懂、计算效率高**，而且模型的系数可以直观反映每个特征对结果的影响方向和程度，因此常被作为分类问题的基线模型。

逻辑回归线性组合公式：

课设勿盗

$$z = w_1x_1 + w_2x_2 + \cdots + w_nx_n + b = \sum_{i=1}^{n} w_i\, x_i + b \tag{1}$$

Sigmoid 函数表达式：

$$p = \sigma(z) = \frac{1}{1 + e^{-z}} \tag{2}$$

3.1.2 模型构建与训练

在本次比赛中，我将清洗和处理后的乘客数据（如年龄、性别、船舱等级等特征）作为输入，如图 1 乘客的生存情况（0 表示未生存，1 表示生存）作为输出，如图 2 根据年龄的乘客的生存情况，如图 3 根据性别的乘客的生存情况，如图 4 根据船舱等级的乘客的生存情况，使用 Python 中的 scikit - learn 库构建逻辑回归模型。通过 LogisticRegression() 函数初始化模型对象，并将处理好的训练数据集输入到 fit() 方法中进行训练，模型会自动学习每个特征的权重，找到能最大程度区分生存与未生存乘客的参数组合。

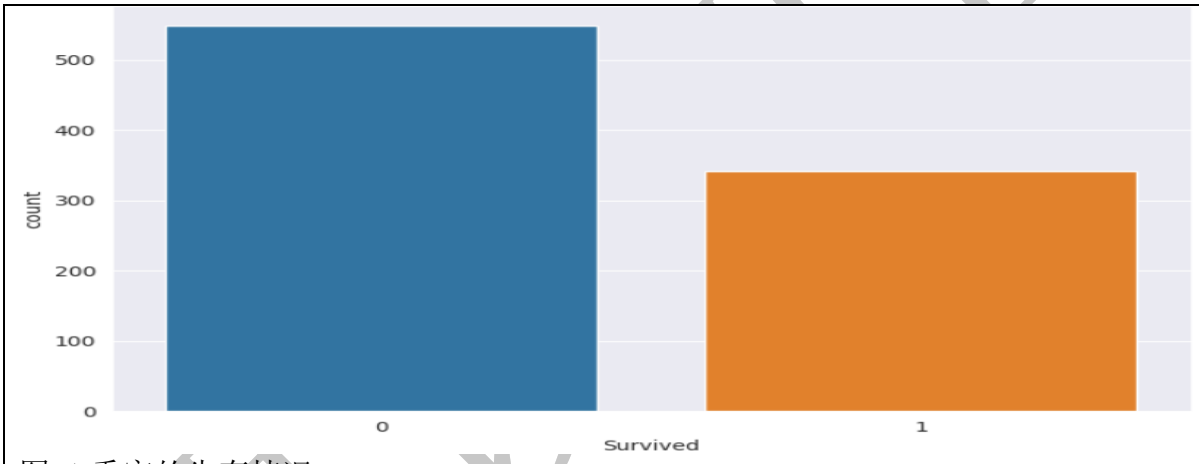

图 1 乘客的生存情况

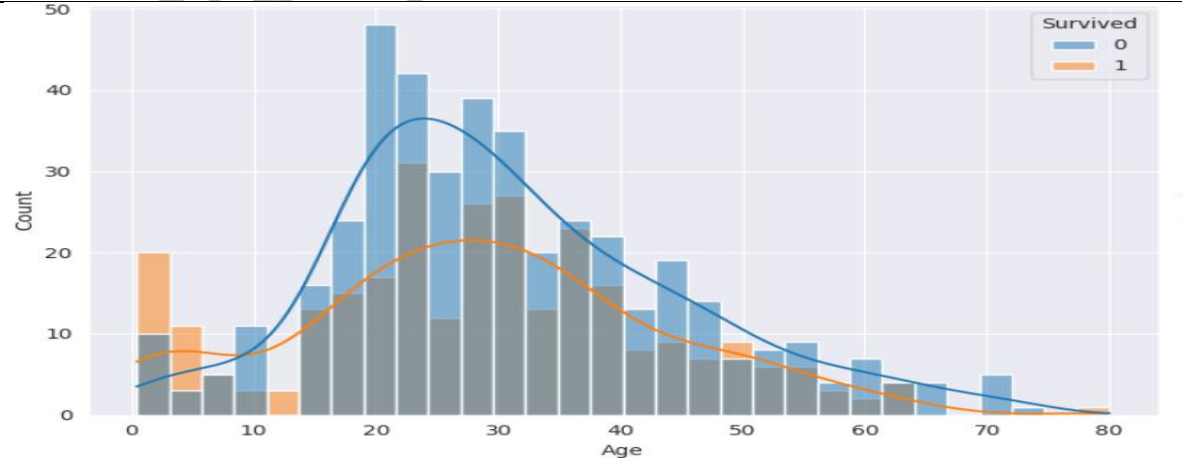

图 2 根据年龄的乘客的生存情况

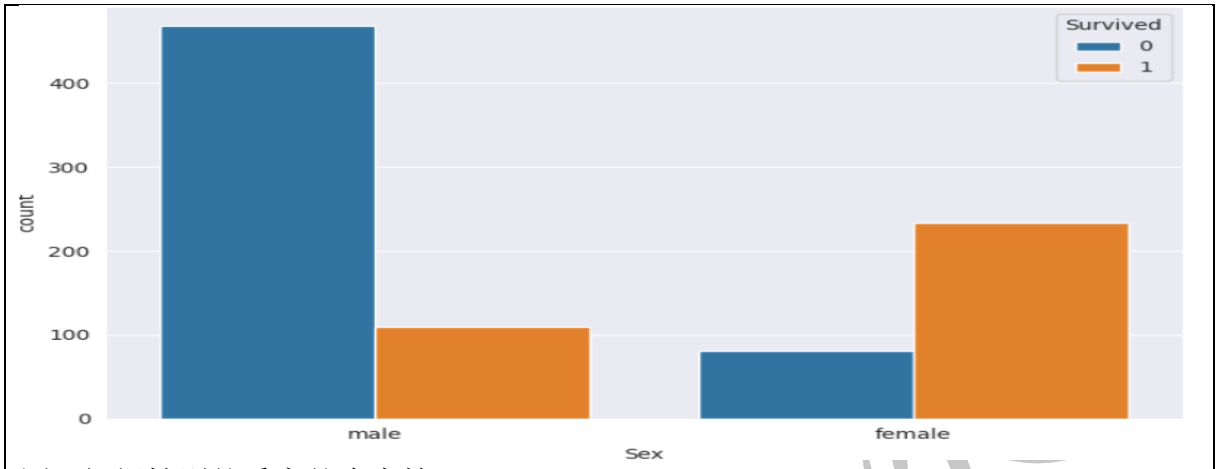

图 3 根据性别的乘客的生存情况

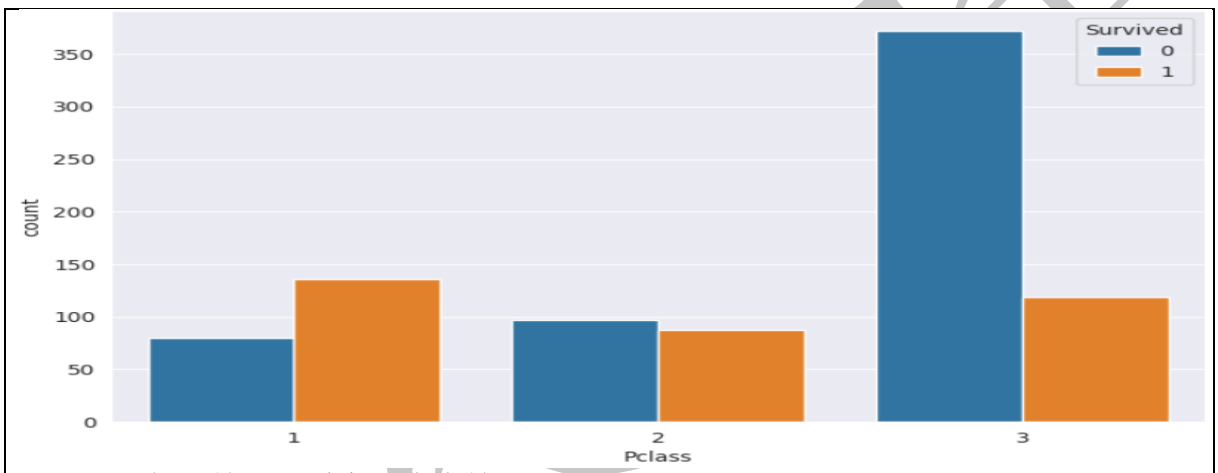

图 4 根据船舱等级的乘客的生存情况

3.1.3 模型优化

为了提升逻辑回归模型的预测性能，我进行了**超参数调优**。逻辑回归的关键超参数包括 C （正则化强度的倒数），它用于控制模型复杂度，**避免过拟合**。我采用网格搜索（Grid Search）方法，预先设定一系列 C 的候选值（如[0.01, 0.1, 1, 10, 100]），结合 5 折交叉验证，对每个候选值都训练并评估模型在验证集上的性能（如准确率、F1 值），最终选择使模型性能最优的 C 值来确定最终的逻辑回归模型。此外，我还对数据进行了**标准化处理**，将特征缩放到相同的尺度，使模型训练更快收敛，进一步优化模型效果。

3. 2 随机森林算法模型

3.2.1 模型介绍

随机森林是一种基于决策树的**集成学习算法**，它通过构建多棵决策树，并将这些树的预测结果进行汇总（分类问题通常采用**投票法**，回归问题采用**平均法**）来做出最终判断。每棵决策树在训练时，会随机选取部分样本和特征进行生长，这使得每棵树

都具有一定差异，**降低了**模型的**过拟合**风险。决策树各自基于不同的信息和角度给出判断，最后综合投票，得出更可靠的结论。在泰坦尼克号生存预测中，随机森林可以综合考虑乘客的年龄、性别、船舱等级等多个特征，通过多棵决策树的“集体智慧”，更准确地预测乘客是否能够生存。

基尼系数公式：

$$Gini(p) = 1 - \sum_{k=1}^{K} p_k^2 \tag{3}$$

最终预测公式：

$$\hat{y} = \backslash undersetc \in \mathcal{Y} \arg m\, ax \sum_{i=1}^{M} I(h_i(x) = c) \tag{4}$$

3.2.2 模型构建与训练

使用 Python 的 scikit-learn 库构建随机森林模型。通过 RandomForestClassifier() 函数初始化模型对象，将处理好的训练数据集（包含乘客特征和生存情况标签）输入到 fit() 方法中进行训练。在训练过程中，模型会自动生成多棵决策树，每棵树**根据随机选取的样本子集和特征子集进行分裂和生长，学习数据中的规律和模式**。如图 5，展示“死亡”“生存”两类分类任务中，precision（精确率）、recall（召回率 ）、f1 - score（F1 分数，综合精确率和召回率的指标 ）及 support（样本数量），还给出整体 accuracy（准确率）、macro avg（宏平均，对各类指标简单平均 ）、weighted avg（加权平均，按样本数加权平均 ），用于评估模型分类效果 。如图 6 随机森林模型 ROC 曲线图中 AUC=0.89，证明随机森林模型效果好。

分类性能指标报告

	precision	recall	f1-score	support
死亡	0.84	0.86	0.85	105.000000
生存	0.79	0.77	0.78	74.000000
accuracy	0.82	0.82	0.82	0.820000
macro avg	0.82	0.81	0.81	179.000000
weighted avg	0.82	0.82	0.82	179.000000

图 5 分类性能指标图

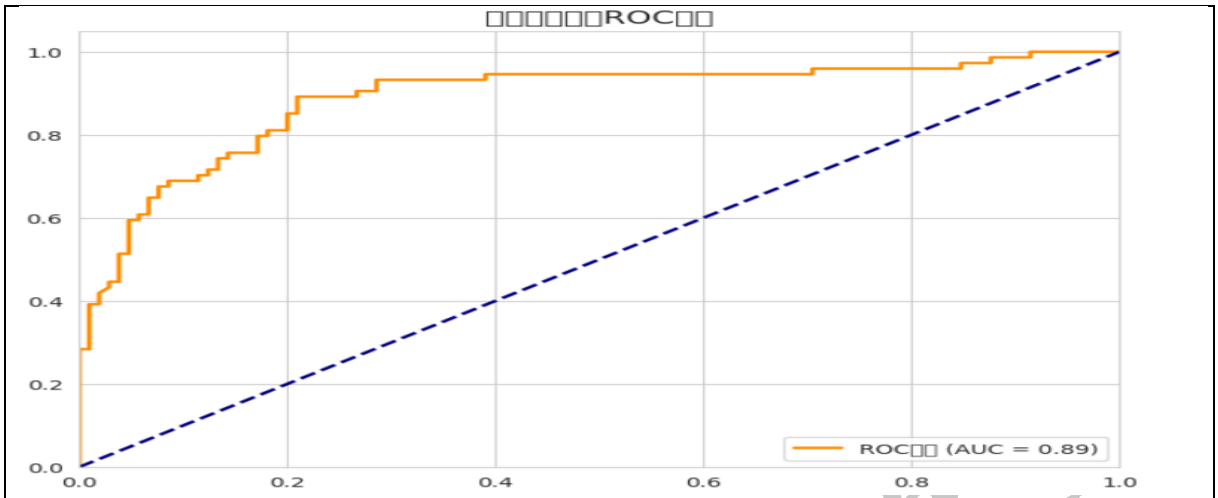

图 6 随机森林模型 ROC 曲线

3.2.3 模型优化

为了提升随机森林模型的预测性能，我对关键超参数进行了调优。核心超参数包括：（1）、 n_estimators ：决策树的数量。树的数量越多，模型的“集体智慧”越强，但计算成本也会增加，容易过拟合。（2）、 max_depth ：每棵决策树的最大深度，限制树的生长程度，避免过拟合。我采用网格搜索结合交叉验证的方法，预先设定超参数的候选值，例如 n_estimators 取[50,100, 200, 300]， max_depth 取[3, 5, 7, 9,12,None]，对每一种超参数组合训练模型，并通过 5 折交叉验证评估模型在验证集上的性能（如准确率、F1 值），选择使模型性能最优的超参数组合。此外，还对数据进行了标准化处理，使不同特征处于相同尺度，帮助模型更高效地学习特征间的关系，进一步优化模型预测效果。经图 7，图 8 折线图分析最优参数为: {'max_depth': 7, 'n_estimators': 200, }，此时交叉验证最高准确率为: 0.8350。

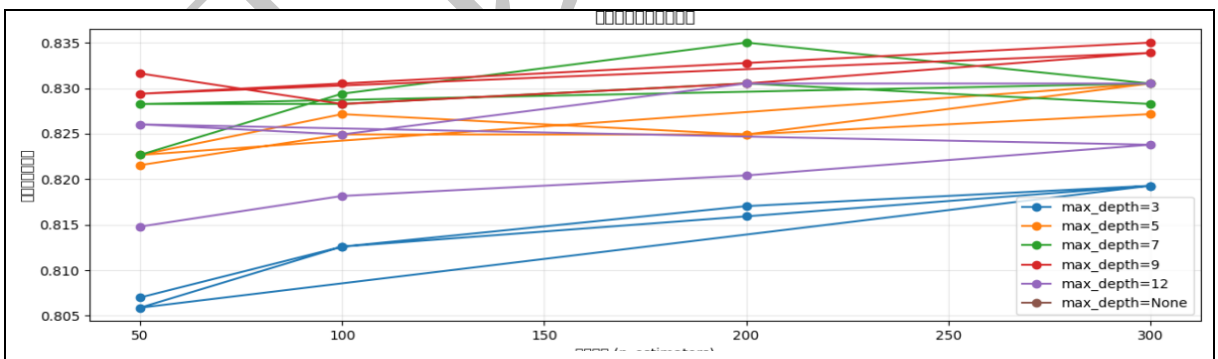

图 7 n_estimators 与准确率的关系（不同 max_depth）

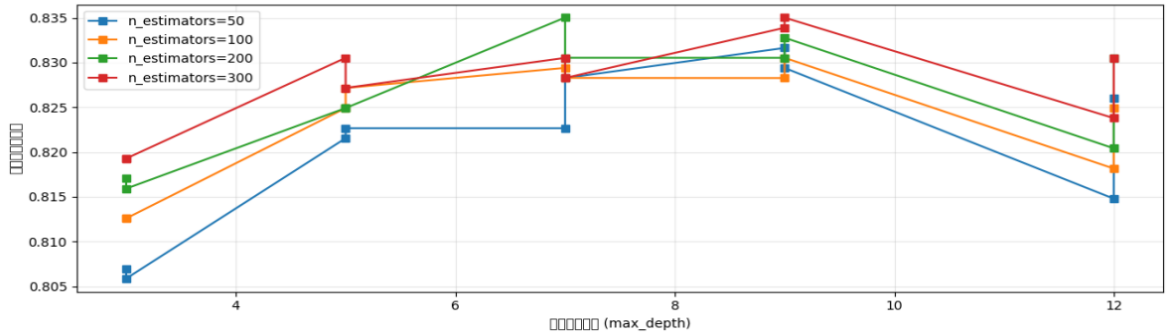

图 8 max_depth 与准确率的关系（不同 n_estimators）

3.3 XGBoost 梯度提升树模型

3.3.1 模型介绍

XGBoost（eXtreme Gradient Boosting）是一种基于梯度提升算法的**集成学习模型**，它通过迭代训练多棵决策树来逐步减少预测误差。与随机森林并行构建多棵树不同，XGBoost 的每棵树都会基于前一棵树的预测残差（即真实值与预测值的差值）进行训练，每棵树都在修正上一棵树的“错误”，从而不断逼近真实结果。XGBoost 还引入了**正则化项**来**控制模型复杂度**，**防止过拟合**，并且对树的生长过程进行了优化，**训练速度更快、性能更稳定**。在泰坦尼克号生存预测中，XGBoost 能够有效挖掘乘客特征（如年龄、性别、船舱等级等）与生存结果之间的复杂关系，通过多棵树的接力协作，做出更准确的预测。

均方误差损失（回归）公式：

$$L(y,\hat{y}) = \frac{1}{2n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2 \tag{5}$$

梯度计算公式：

$$r_{ti} = -\left[\frac{\partial L\left(y_i, \widehat{y_i^{(t-1)}}\right)}{\partial \widehat{y_i^{(t-1)}}}\right] = y_i - \widehat{y_i^{(t-1)}} \tag{6}$$

拟合残差分布公式：

$$\widehat{y_i^{(t)}} = \widehat{y_i^{(t-1)}} + \eta \cdot f_t(x_i) \tag{7}$$

3.3.2 模型构建与训练

使用 Python 中的 xgboost 库构建 XGBoost 模型。首先通过 XGBClassifier() 函数初始化模型对象，将经过数据预处理后的训练数据集（包含乘客特征和生存情况标签）输入到 fit() 方法中进行训练。在训练过程中，模型会从第一棵树开始，根据数据**计算预测残差**，然后基于残差训练下一棵树，不断迭代，直到达到预设的树的数量或满足停止条件，逐步构建出一个由多棵决策树组成的强预测模型。如图 9，XGBoost 特征重要性图直观显示哪些特征对预测泰坦尼克号乘客生存影响最大。图 10 XGBoostROC 曲线图中 AUC=0.90，证明 XGBoost 模型效果更好。

课设分享

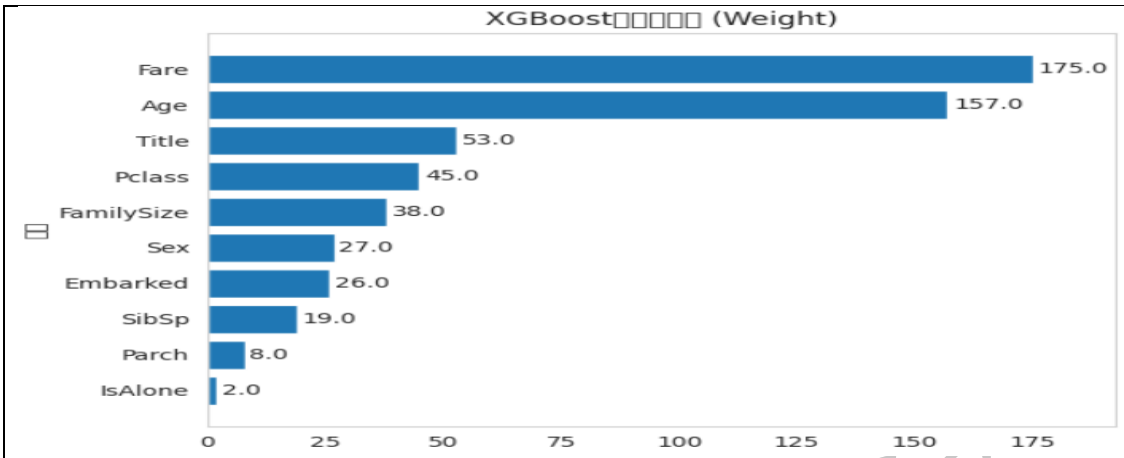

图 9 XGBoost 特征重要性图

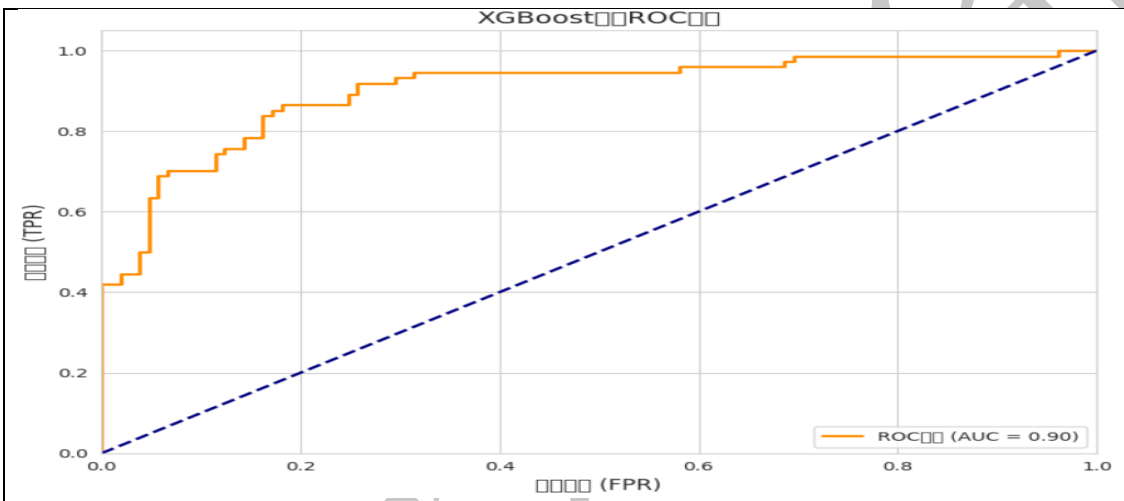

图 10 XGBoost 模型 ROC 曲线图

3.3.3 模型优化

为了提升 XGBoost 模型的预测性能，我对关键超参数进行调优。主要超参数包括：（1）、 n_estimators：迭代的树的数量，数量越多模型的拟合能力越强，但计算时间会增加，也容易过拟合。（2）、 learning_rate：学习率，控制每棵树对预测结果的贡献程度，较小的学习率可以使模型训练更稳定，但需要更多的迭代次数。（3）、 max_depth：每棵决策树的最大深度，用于限制树的复杂程度，防止过拟合。我采用随机搜索结合交叉验证的方法寻找最优超参数组合。先设定超参数的取值范围，如 n_estimators 在[50, 100, 200,300]间随机取值，learning_rate 在[0.01,0.05, 0.1, 0.2, 0.3]间随机取值，max_depth 在[3, 5, 7, 9]间随机取值，对每个随机生成的超参数组合训练模型，并通过 5 折交叉验证评估模型在验证集上的准确率、F1 值等指标，最终选择性能最优的超参数组合。此外，对数据进行**归一化处理**，使特征处于相同尺度，也能帮助 XGBoost 模型更高效地训练和学习，进一步优化预测效果。经图 11，图 12，图 13，图

14 分析知，最优参数为: {'learning_rate': 0.05, 'max_depth': 5, 'n_estimators': 200, 'random_state': 42}，交叉验证最高准确率为: 0.8306, XGBoost 训练集准确率: 0.8878。

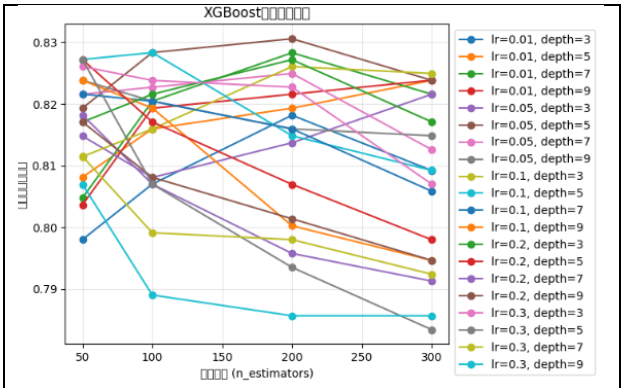

图 11 n_estimators 与准确率的关系（不同 learning_rate）

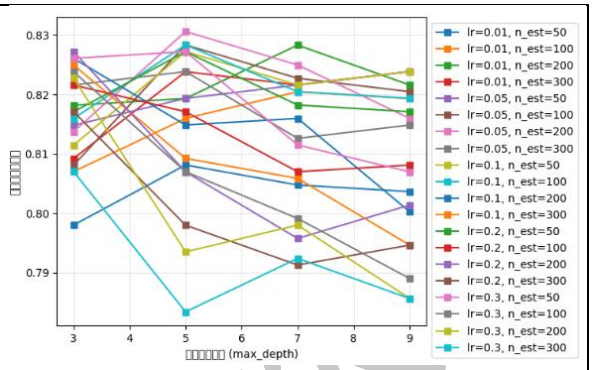

图 12 max_depth 与准确率的关系（不同 learning_rate）

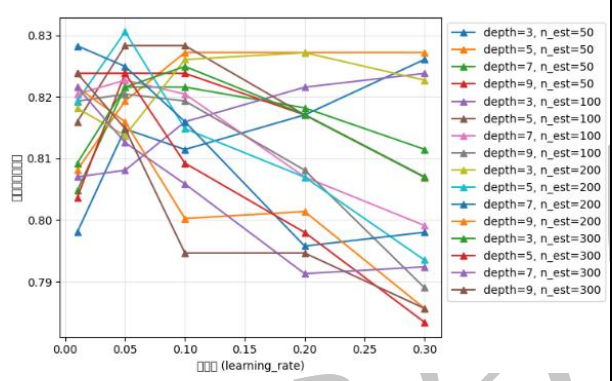

图 13 learning_rate 与准确率的关系（不同 n_estimators）

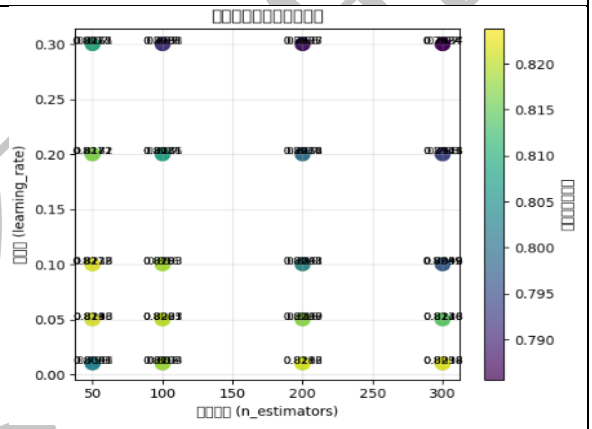

图 14 三维参数组合热力图（简化为二维透视）

3.4 SVM 模型

3.4.1 模型介绍

支持向量机（Support Vector Machine，简称 SVM）是一种**有监督**的机器学习模型，主要用于**分类和回归任务**。对于分类问题，SVM 的核心思想是在特征空间中找到一个**最优超平面**，这个超平面能够将不同类别的样本尽可能分开，并且使不同类别样本到超平面的间隔（Margin）最大。离超平面最近的那些样本点被称为“支持向量”，它们决定了超平面的位置。例如在泰坦尼克号生存预测中，SVM 会根据乘客的年龄、性别、船舱等级等特征，在多维空间中寻找一个最佳的划分边界，将生存和未生存的乘客区分开来。对于线性不可分的数据，SVM 还可以通过核函数将数据映射到更高维的空间，从而找到合适的超平面。

标准化公式：

$$x_{\text{scaled}} = \frac{x - \mu}{\sigma} \tag{8}$$

SVM 间隔最大化公式：

$$\min_{w,b,\xi} \quad \frac{1}{2}||w||^2 + C\sum_{i=1}^{n}\xi_i$$

$$\text{subject to} \quad y_i(w^T x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0 \tag{9}$$

RBF 核函数：

$$K(x_i, x_j) = \exp(-\gamma|x_i - x_j|^2) \tag{10}$$

置换特征重要性公式：

$$I_f = A - A_f \tag{11}$$

交叉验证公式：

$$\text{Average Accuracy} = \frac{1}{k}\sum_{i=1}^{k} A_i \tag{12}$$

3.4.2 模型构建与训练

在 Python 中，使用 scikit-learn 库的 SVC() 函数（用于分类任务）来构建 SVM 模型。将经过数据预处理后的训练数据集（包含乘客特征和生存情况标签）输入到 fit() 方法中进行训练。在训练过程中，模型会根据数据的分布情况，寻找能够最大化间隔的超平面参数，确定支持向量的位置。如果数据在原始特征空间中线性不可分，还可以选择合适的核函数（如径向基函数 RBF、多项式核函数等），将数据映射到更高维空间后再寻找超平面。如图 15 SVM 用 RBF 核函数对数据分类的可视化结果，展示了不同类别样本（点）在二维特征空间的分布，以及 SVM 学习到的分类边界（曲线），辅助理解模型对数据的划分效果 。图 16 SVMROC 曲线图中 AUC=0.94，证明 SVM 模型效果更好。

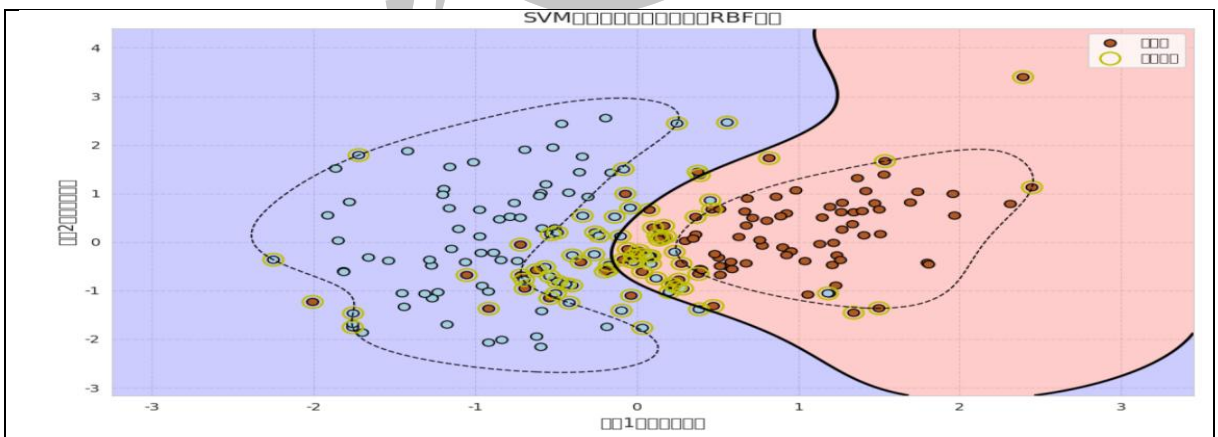

图 15 SVM 用 RBF 核函数对数据分类的可视化结果图

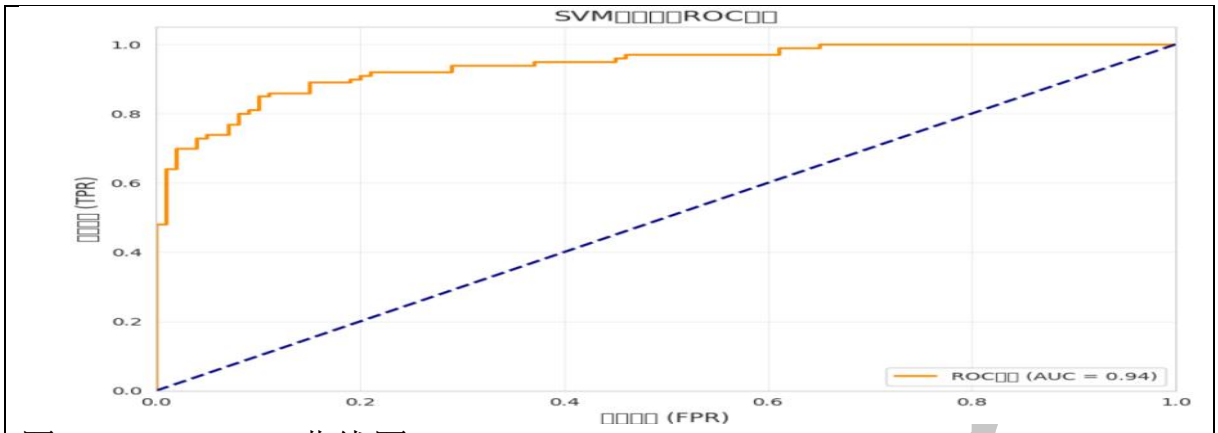

图 16 SVMROC 曲线图

3.4.3 模型优化

为了提升 SVM 模型的预测性能，我对关键超参数进行调优：（1）、C：惩罚参数，用于控制对错误分类样本的惩罚程度。C 值越小，允许的间隔越大，模型越简单，可能会出现欠拟合；C 值越大，对错误分类的惩罚越重，模型复杂度增加，容易过拟合。（2）、kernel：核函数类型，常用的有'linear'（线性核）、'rbf'（径向基核）、'poly'（多项式核）等。不同的核函数适用于不同分布的数据，例如 rbf 核函数适用于数据分布较为复杂、非线性的情况。我采用网格搜索结合交叉验证的方法来寻找最优超参数组合。预先设定 C 和 kernel 的候选值，如 C 取[0.1, 1, 10]，kernel 取 ['linear', 'rbf']，对每一种超参数组合训练模型，并通过 5 折交叉验证评估模型在验证集上的准确率、F1 值等指标，最终选择使模型性能最优的超参数组合。此外，对数据进行标准化处理，将特征缩放到相同的尺度，能够帮助 SVM 更高效地找到最优超平面，进一步提升模型的预测效果。由图 17 可知当最优惩罚参数 C: 10，对应准确率: 0.8216。

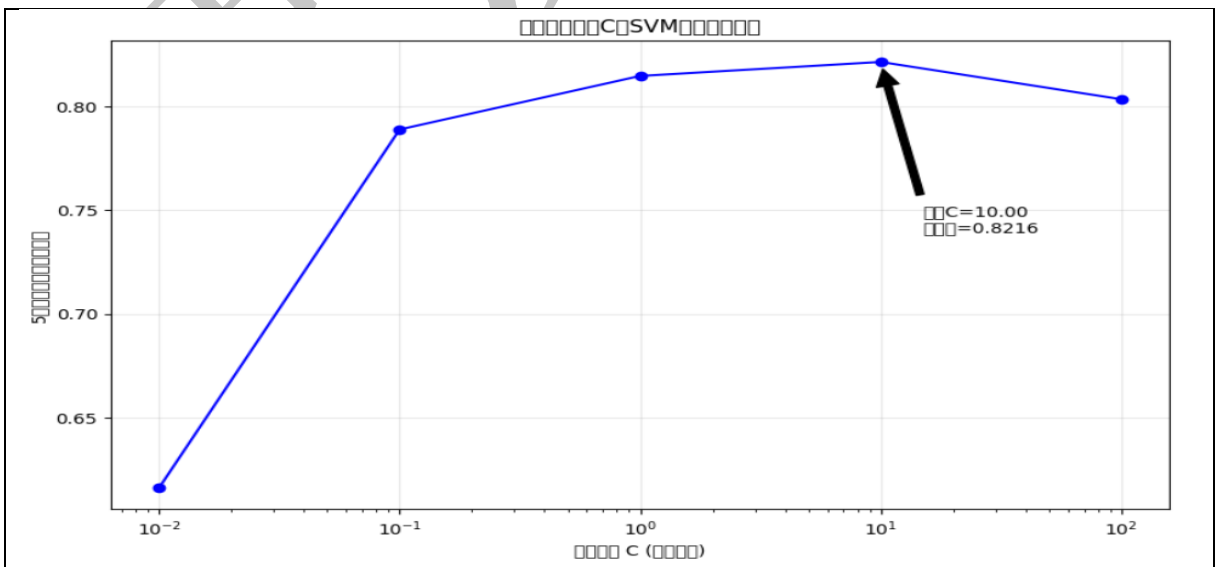

图 17 不同惩罚参数 C 对 SVM 准确率的影响

3.5 模型集成

1.模型集成的概念

模型集成（Model Ensemble）是指将**多个机器学习模型的预测结果进行组合**，以获得更优性能的方法。这些模型可以是同类型（如多个决策树）或不同类型（如逻辑回归、随机森林等），通过特定策略（如投票、平均、堆叠等）整合结果，提升整体预测的准确性、鲁棒性和泛化能力。

2.模型集成的可以达到的效果

（1）、**降低误差**：单个模型可能因偏差（Bias）或方差（Variance）导致预测失误，集成通过组合不同模型可平衡误差。例如：随机森林通过多棵决策树减少方差，提升稳定性。（2）、**提升泛化能力**：不同模型捕捉数据的角度不同，集成可覆盖更多特征模式，减少过拟合风险。例如：逻辑回归擅长线性关系，SVM 适合非线性边界，集成可结合两者优势。（3）、**增强鲁棒性**：单个模型可能对异常数据敏感，集成通过“多数表决”降低个别模型的错误影响。（4）、**突破单一模型局限**：集成可结合不同算法的优点，例如 XGBoost 的强拟合能力与随机森林的抗噪声能力。

如图 18 逻辑回归交叉验证平均准确率: 0.8249 (±0.0216)，随机森林交叉验证平均准确率: 0.8036 (±0.0264)，XGBoost 交叉验证平均准确率: 0.8238 (±0.0258)，SVM 交叉验证平均准确率: 0.8149 (±0.0365)。模型集成权重为:逻辑回归权重: 0.2525，随机森林权重: 0.2460，XGBoost 权重: 0.2521，SVM 权重: 0.2494，加权集成准确率（交叉验证平均）: 0.2042。

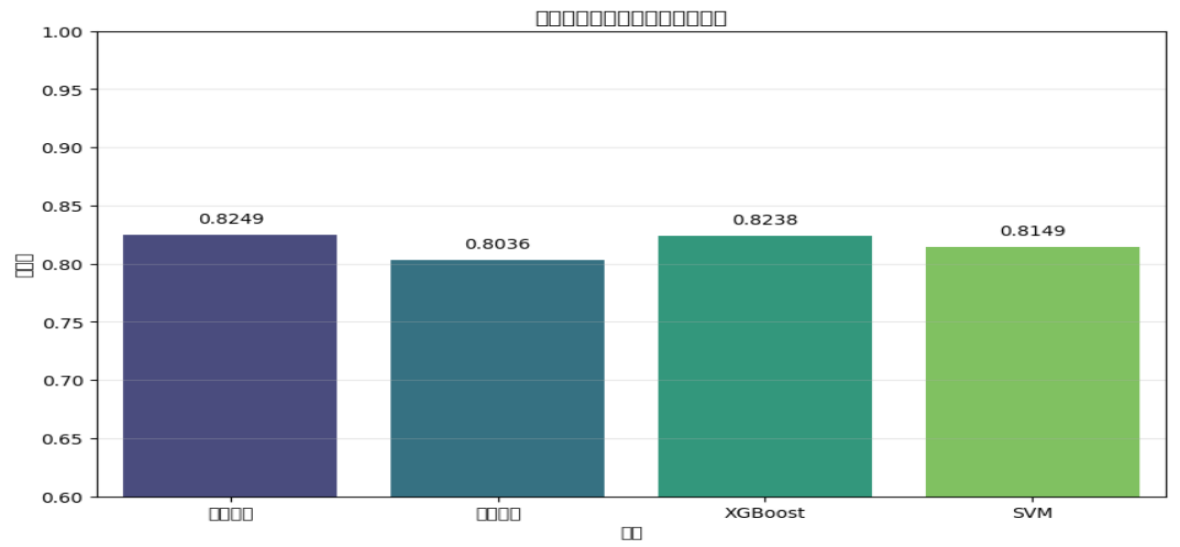

图 18 模型性能对比可视化

四、总结

1、模型总结对比

1.逻辑回归：**简单易解释**，基于线性关系建模生存概率，**计算高效、训练快**，但

对复杂非线性关系拟合能力弱，适合初步 baseline 搭建，通过特征系数可**直观**理解特征对生存的影响。

2.随机森林：基于决策树集成，**能处理非线性关系**，对缺失值、异常值鲁棒，可**降低过拟合风险**，在泰坦尼克号数据（含多类型特征、存在噪声）中表现稳定，但易因树过深等导致过拟合，需合理调参。

3.XGBoost：梯度提升框架，**迭代优化损失函数，对复杂数据拟合能力强**，支持正则化、特征重要性分析，在竞赛中常出优异结果，不过训练相对慢，对计算资源有一定要求。

4.SVM（支持向量机）：寻找**最优超平面**对数据分类，适合小/中等规模数据集，对**高维数据**友好，若数据线性不可分需依赖核技巧（如 RBF 核）映射到高维空间，但调参（核函数、正则化等）复杂，对泰坦尼克号这类样本量不大但特征有一定复杂度的数据，效果受核函数选择影响明显。

5. 模型集成后准确率低于单个模型，可能原因包括：(1) 基模型相关性过高，特别是随机森林与 XGBoost 都基于决策树，导致集成时信息冗余；(2) 权重分配未优化，简单的平均加权未能发挥各模型优势；(3) 集成策略选择不当，硬投票方式可能放大了某些模型的错误。未来改进方向：(1) 选择差异性更大的基模型组合；(2) 使用堆叠(Stacking)等更高级的集成方法；(3) 优化模型权重分配策略实际比赛中，需结合数据预处理（如缺失值填充、特征编码）、超参数调优（网格搜索、交叉验证），综合模型表现（准确率、泛化能力等）选择。

2、个人总结

在本次 Kaggle 泰坦尼克号生存预测竞赛中，我将机器学习理论应用于实际问题，完成了从**数据预处理、模型构建到优化**的完整流程。在数据预处理阶段，通过**填补缺失值、编码分类变量和特征工程**，将原始数据转化为适合模型训练的格式。特别是对年龄、船舱等级等特征的处理，为模型学习提供了有效信息。模型构建中运用 SVM、逻辑回归、随机森林等模型，SVM 通过核函数找最优超平面分类，逻辑回归基于线性关系对生存概率建模，随机森林借多棵决策树投票预测。通过超参数调优（手动调整与网格搜索确定最佳参数）和交叉验证评估泛化能力以减少过拟合。集成环节融合多模型预测结果，采用投票法等策略想要提升预测稳定性与准确率。综合比较各模型表现：SVM 模型展现出最佳性能(AUC=0.94)，表明泰坦尼克号生存预测问题中，基于 RBF 核的非线性分类效果最好；XGBoost(AUC=0.90)和随机森林(AUC=0.89)表现次之，但训练效率更高； 逻辑回归作为基线模型，达到了可接受的准确率(0.82)且解释性强；当前集成方法未能提升性能，需进一步优化集成策略。

通过本次实践，我不仅进一步了解了机器学习从数据处理到模型部署的全流程操作，也理解了不同模型的特性及集成学习的优势。未来可以进一步探索更复杂的模型集成方法或尝试深度学习模型，为类似的预测任务提供更优解决方案。

课设外盗